
Суммаризация научных подборок в задаче автоматической генерации обзоров

A Preprint

Дегтев Василий Денисович
МГУ им. М.В. Ломоносова
Москва, Россия
DegtevVD@my.msu.ru

Ищенко Роман Валерьевич
МГУ им. М.В. Ломоносова
Москва, Россия
ischenkorv@my.msu.ru

Abstract

Автоматическая генерация обзора литературы является важной задачей в области автоматической обработки научных публикаций и направлена на создание релевантных и контекстуально уместных цитат для поддержки аргументации в академических текстах. Появление сверхбольших языковых моделей значительно продвинуло исследование в этой области: на сегодняшний день большинство существующих подходов так или иначе основаны на использовании больших языковых моделей (БЯМ). В данной работе исследуется возможность достижения сопоставимого качества генерации обзоров литературы с помощью предварительно обученной языковой модели, имеющей значительно меньшее число параметров, при условии тщательного подбора промптов. Также обсуждаются потенциальные применения генерации цитирующего текста в системах поддержки научного письма, автоматической аннотации научных работ и интеллектуальных помощниках для исследователей.

1 Введение

Качественный обзор литературы является важной частью любой научной работы, обеспечивая контекст и обосновывая актуальность исследования. Однако его подготовка — трудоемкий процесс. В связи с этим автоматическая генерация обзора литературы, направленная на создание релевантных и контекстуально уместных цитат для поддержки аргументации, стала одной из важных задач в области обработки научных публикаций.

На сегодняшний день большинство передовых подходов в генерации текста цитирования опираются на использование Больших Языковых Моделей (БЯМ), число параметров которых может насчитывать десятки или сотни миллиардов.

В данной работе мы исследуем гипотезу о том, что добиться сопоставимого качества генерации цитирующего текста (citation text generation) возможно с помощью языковой модели, имеющей значительно меньшее число параметров. Мы предполагаем, что ключом к достижению этой цели является не экстенсивный рост модели, а интенсивный подход - дообучение и выравнивание путем комбинирования подходов дообучения с учителем (supervised fine-tuning), обучения с подкреплением и тщательного подбора промптов (prompt engineering).

Большинство работ направлено на генерацию текста цитирования отдельных статей [AbuRa'ed et al., 2020, Şahinuç et al., 2024, Gu and Hahnloser, 2023a, Arita et al., 2022], и лишь некоторые статьи предлагают генерацию текста для ссылки сразу на несколько источников [Wu et al., 2021, Anand et al., 2023]. Все работы так или иначе рассматривают генерацию лишь отдельных предложений. Мы же предлагаем инструмент для генерации целых абзацев связного текста цитирований.

2 Обзор литературы

2.1 Подходы к решению

Ранние работы, такие как [Hu and Wan, 2014], использовали тематическое моделирование и классические методы машинного обучения для экстрактивного выделения текста цитирования. Современные же решения основаны на БЯМ с трансформерной архитектурой, которые впервые были применены в [Xing et al., 2020]. Значительный прогресс в качестве генерации цитирующего текста связан с внедрением намерений цитирования (citation intents), предложенные [Wu et al., 2021] с целью повышения качества генерируемых цитат. Этот подход развит в [Jung and Lin, 2022] и [Gu and Hahnloser, 2023a] с использованием обучения с подкреплением (PPO).

Контекстное обогащение стало важным направлением: в [Arita et al., 2022] на вход модели подаются релевантные фрагменты из цитируемых статей, а в [Li et al., 2024] вводится концепция cited text spans — автоматически извлечённых информативных отрывков. Генерация обзоров для нескольких работ одновременно решена в [Anand et al., 2023] с помощью моделей с увеличенным контекстом, способных формировать связные абзацы.

С появлением БЯМ на миллиарды параметров активно применяются техники промптинга: Chain-of-Thought в [Ji et al., 2024], seq2seq-модели с графами знаний в [Anand et al., 2024]. Графовые энкодеры и контрастивное обучение использованы в [Chen et al., 2022] и [Chen et al., 2021] для моделирования связей между документами. Интегрированные пайплайны, такие как SciLit [Gu and Hahnloser, 2023b], сочетают поиск, суммаризацию и генерацию цитирований. Систематическое исследование промптинга и контроля намерений проведено в [Şahinuç et al., 2024].

2.2 Данные

Качество генерации во многом зависит от специализированных датасетов. SciReviewGen [Kasanishi et al., 2023] предоставляет масштабный корпус для генерации обзоров литературы. CORWA [Li et al., 2022] содержит аннотации связанных работ с указанием семантических ролей цитирований. В [Anand et al., 2024] представлен новый датасет с мультидокументными примерами и улучшенными аннотациями. Многие работы используют абстракты или полные тексты из открытых научных репозиторий (arXiv, ACL Anthology), а также предварительно обработанные фрагменты [Li et al., 2024]. В работе [Martin Funkquist, 2023] представлен бенчмарк, основанный на корпусе CORWA.

2.3 Критерия оценки качества

Оценка качества генерации остаётся сложной задачей. Стандартной метрикой является ROUGE [Lin, 2004], измеряющая пересечение n-грамм, однако она недостаточна для оценки семантической точности. Метрика BERTScore [Tianyi Zhang, 2019], основанная на энкодере BERT, позволяет более точно оценить семантическую близость между эталонным текстом и выходами модели. [Şahinuç et al., 2024] использовали вместо обычного BERT модель SciBERT [Iz Beltagy, 2019] для подсчёта BERTScore. Работы [Anand et al., 2024], [Gu and Hahnloser, 2023a] предложили собственные метрики, учитывающие точность цитирований и релевантность контента.

3 Постановка задачи

3.1 Дано

Набор данных $\{(A_j, a_{1j}, \dots, a_{kj}, c_j, G_j), j=1^N\}$ состоит из A_j - аннотации цитирующей статьи, a_{1j}, \dots, a_{kj} - аннотаций цитируемых статей, c_j (citation intent) - цели цитирования, G_j - эталонных текстов цитирований.

3.2 Найти

Обозначим модель за $M = M(\Theta)$, $\Theta = (\theta_1, \dots, \theta_s)$ - вектор параметров модели, размер словаря $|V|$ и длину выходной последовательности T . Отображение модели M из пространства входов X в пространство предсказанных распределений вероятностей Y :

$$M : X \longrightarrow Y$$

где X - пространство входных данных, а Y - последовательность векторов вероятностей, предсказанных моделью:

$$Y = (y_1, y_2, \dots, y_T)$$

Каждый элемент y_t в этой последовательности является вектором (распределением) вероятностей по всему словарю V :

$$y_t \in \mathbb{R}^{|V|}$$

3.3 Критерии

В качестве функции потерь будем использовать кросс-энтропию для casual language modeling. Пусть $Y = (y_1, \dots, y_t), y_t \in \mathbb{R}^{|V|}$ - вероятности для t -ого сгенерированного токена, а $G = (g_1, \dots, g_T), g_t \in \{0, 1\}^{|V|}$ - эталонный текст цитирования. При этом $g_{ti} = 1$, если токен имеет i -й номер в словаре, и $g_{ti} = 0$ иначе. Определим наш функционал потерь как:

$$\mathcal{L}_{CE} = -\frac{1}{T} \sum_{i=1}^T \log(y_i) \cdot g_t \quad (1)$$

3.4 Внешние критерии оценки качества

Для оценки качества сгенерированных ответов будем использовать BERTScore [Tianyi Zhang, 2019], аналогично [Şahinuç et al., 2024] в качестве эмбедадера будем использовать SciBERT [Iz Beltagy, 2019]. Пусть:

- $G = (g_1, \dots, g_t)$ - эталонная последовательность.
- $Y = (y_1, \dots, y_t)$ - сгенерированная последовательность.
- $\hat{y}_j, \hat{g}_j \in \mathbb{R}^{|V|}$ - векторы эмбедингов для токенов y_i и g_j .
- $w(t)$ - IDF-вес для токена t .
- $s(\hat{a}, \hat{b}) = \frac{\hat{a} \cdot \hat{b}}{\|\hat{a}\| \|\hat{b}\|}$.

$$R_{BERT} = \frac{\sum_{i=1}^m w(y_i) \max_{j=1}^n s(\hat{y}_i, \hat{g}_j)}{\sum_{i=1}^m w(y_i)} \quad (2)$$

$$P_{BERT} = \frac{\sum_{j=1}^n w(g_j) \max_{i=1}^m s(\hat{y}_i, \hat{g}_j)}{\sum_{j=1}^n w(g_j)} \quad (3)$$

$$F_{BERT} = 2 \frac{P_{BERT} \cdot R_{BERT}}{P_{BERT} + R_{BERT}} \quad (4)$$

Список литературы

- Ahmed AbuRa'ed, Horacio Saggion, Alexander Shvets, and Àlex Bravo. Automatic related work section generation: experiments in scientific document abstracting. 2020.
- Furkan Şahinuç, Ilia Kuznetsov, Yufang Hou, and Iryna Gurevych. Systematic task exploration with llms: A study in citation text generation. 2024.

- Nianlong Gu and Richard H. R. Hahnloser. Controllable citation sentence generation with language models. 2023a.
- Akito Arita, Hiroaki Sugiyama, Kohji Dohsaka, Rikuto Tanaka, and Hirotoshi Taira. Citation sentence generation leveraging the content of cited papers. 2022.
- Jia-Yan Wu, Alexander Te-Wei Shieh, Shih-Ju Hsu, and Yun-Nung Chen. Towards generating citation sentences for multiple references with intent control. 2021.
- Avinash Anand, Kritarth Prasad, Ujjwal Goel, Mohit Gupta, Naman Lal, Astha Verma, and Rajiv Ratn Shah. Context-enhanced language models for generating multi-paper citations. 2023.
- Yue Hu and Xiaojun Wan. Automatic generation of related work sections in scientific papers: An optimization approach. 2014.
- Xinyu Xing, Xiaosheng Fan, and Xiaojun Wan. Automatic generation of citation texts in scholarly papers: A pilot study. 2020.
- Shing-Yun Jung and Ting-Han Lin. Intent-controllable citation text generation. 2022.
- Xiangci Li, Yi-Hui Lee, and Jessica Ouyang. Cited text spans for scientific citation text generation. 2024.
- Bin Ji, Huijun Liu, Mingzhe Du, and See-Kiong Ng. Chain-of-thought improves text generation with citations in large language models. 2024.
- Avinash Anand, Ashwin R. Nair, Kritarth Prasad, Vrinda Narayan, Naman Lal, Debanjan Mahata, Yaman K. Singla, and Rajiv Ratn Shah. Advances in citation text generation: Leveraging multi-source seq2seq models and large language models. 2024.
- Xiuying Chen, Hind Alamro, Mingzhe Li, Shen Gao, Rui Yan, Xin Gao, and Xiangliang Zhang. Target-aware abstractive related work generation with contrastive learning. 2022.
- Xiuying Chen, Hind Alamro, Mingzhe Li, Shen Gao, Xiangliang Zhang, Dongyan Zhao, and Rui Yan. Capturing relations between scientific papers: An abstractive model for related work section generation. 2021.
- Nianlong Gu and Richard H. R. Hahnloser. Scilit: A platform for joint scientific literature discovery, summarization and citation generation. 2023b.
- Tetsu Kasanishi, Masaru Isonuma, Junichiro Mori, and Ichiro Sakata. Scireviewgen: A large-scale dataset for automatic literature review generation. 2023.
- Xiangci Li, Biswadip Mandal, and Jessica Ouyang. Corwa: A citation-oriented related work annotation dataset. 2022.
- Yufang Hou Iryna Gurevych Martin Funkquist, Ilia Kuznetsov. Citebench: A benchmark for scientific citation text generation. 2023.
- Chin-Yew Lin. Rouge: A package for automatic evaluation of summaries. 2004.
- Felix Wu Kilian Q. Weinberger Yoav Artzi Tianyi Zhang, Varsha Kishore. Bertscore: Evaluating text generation with bert. 2019.
- Arman Cohan Iz Beltagy, Kyle Lo. Scibert: A pretrained language model for scientific text. 2019.